

MatchViT: Light-weight Vision Transformer with Matching Separable Self-attention

Elliott Rakotondramanitra Louis-Antoine Pham

ICLR 2026 Conférence

Introduction

L'article présente un nouveau mécanisme d'attention linéaire afin de pallier le problème de la complexité quadratique $O(N^2)$ des Vision Transformers. De nombreuses approches ont été proposées pour réduire cette complexité, notamment la Separable Self-Attention (SSA), qui agrège l'information contextuelle dans un vecteur unique appliqué à tous les tokens de sortie (Mehta & Rastegari, 2023), permettant ainsi d'atteindre une complexité en $O(N)$. Cependant, des études ont montré que chaque token nécessite des informations spécifiques. C'est pourquoi les auteurs proposent la Matching Separable Self-Attention (MaSSA), qui constitue la brique principale de leur nouveau modèle light-weight, MatchViT[1] s'inspirant du modèle MobileViTv2[2].




Figure 1 : Illustration des différentes méthodes d'attention

Contributions

- **Matching Separable Self-Attention (MaSSA)** : mécanisme d'attention linéaire (complexité $O(N)$) qui permet d'apprendre plusieurs niveaux de caractéristiques au sein du contexte et les appliquer aux tokens correspondants.
- **context-gated FFN** : bloc Feed-Forward qui réutilise les informations de contexte de MaSSA pour extraire des caractéristiques spécifiques à chaque token, améliorant la précision.
- **MatchViT** : modèle light-weight hybride CNN-ViT basé sur les modules MaSSA et context-gated FFN.

Matching Separable Self-Attention MaSSA




Figure 2 : Architecture de MaSSA

- Softmax appliqué à la matrice I pour générer k Context scores (CS) .
- Multiplication avec tous les tokens de K pour avoir les Context Vectors (CV).

- Produit entre les CV et R pour avoir le Matching Score de chaque vecteurs.
- Pondération des CV pour obtenir les Matched CV puis multiplication élément par élément avec V .

Context-gated FFN

Comparé au FFN standard, le context-gated FFN réutilise les Context Vectors issus de MaSSA.




Figure 3 : Architecture du Context-gated FFN

Le processus global du Context-gated FFN se résume à :

$$y = (\sigma(xW_1) * \sigma(xW_k cvW_{cv}))W_2, \quad (1)$$

Architecture MatchViT

L'architecture MatchViT est un modèle qui alterne des blocs convolutifs légers (MV2) pour réduire la résolution spatiale venant du modèle MobileViT et des blocs Transformer (MaViT) pour approfondir les caractéristiques sur quatre étapes progressives, jusqu'à la classification finale .

Stage	Res.	Type	In Ch.	Head	Rep.
Stem	256	Conv $3 \times 3 \downarrow$	3	-	1
	128	MV2 $\downarrow$	32α		
Stage 1	64	MV2 $\downarrow$	32α	4	2
		MaViT	64α		
Stage 2	32	MV2 $\downarrow$	64α	8	3
		MaViT	128α		
Stage 3	16	MV2 $\downarrow$	128α	16	4
		MaViT	256α		
Stage 4	8	MV2 $\downarrow$	256α	32	3
		MaViT	512α		
Post.	4	Global Pool	512α	-	1
		Classifier			

Figure 4 : Architecture MatchViT

Datasets et Expérimentation

- Dataset : Imagenette, un sous-ensemble d'ImageNet contenant 10 classes d'une taille de 13394 exemples, taille 256*256, entraîné sur 20 epoch
- Optimization : AdamW, weight_decay=1e-2, lr = 10e-4.
- Technique de régularisation : Dropout, Data-augmentation

Resultat




Figure - Comparaison MACs




Figure - Comparaison Temps de calculs

Model	Attention	Score	Parameters	MACs
matchViT_0.75	MaSSA	76.25	3.5M	0.3G
matchViT_1.5	MaSSA	79.36	13.8M	1.1G
MobileViT	MHA	77.35	1.3M	0.4G
MobileViTS	MHA	81.17	5M	1.8G
matchViT	MHA	78.09	13.1M	1.1G

Table - Comparaison des performances et de la complexité des modèles que nous avons testés.

Model	Params($\downarrow$)	MACs($\downarrow$)	Top-1($\uparrow$)
MatchViT	13.5M	1.3G	80.0%
MatchViT (SSA)	10.9M	1.2G	78.2%
MatchViT (MHA)	11.8M	1.7G	80.9%
MatchViT (w/o CG-FFN)	12.1M	1.3G	79.2%

Table - Etude d'ablation des auteurs.

Critique : MaSSA est-il meilleur que SSA ?

Conclusion

- On arrive à montrer que MaSSA est aussi performant que MHA avec une complexité réduite entre matchViT et MobileViT
- Motivations de MaSSA claires
- Manque de détails pour ré-implémentation du modèle (hyperparamètres pas précisés...)

Références

- [1] Jiacheng LIAO et al. MatchViT : Light-weight Vision Transformer with Matching Separable Self-attention. 2026. URL : <https://openreview.net/forum?id=7EUYamNuJ9>.
- [2] Sachin MEHTA et Mohammad RASTEGARI. Separable Self-attention for Mobile Vision Transformers. 2022. arXiv : 2206.02680 [cs.CV]. URL : <https://arxiv.org/abs/2206.02680>.

lien github : https://github.com/Louis-AntoinS/Deepl_project